Transferencia de RoBERTa-BNE: ¿tamaño del corpus o receta de entrenamiento?

Nov 14, 2026 · @Universidad

Resumen

Los experimentos de la Fase 3 no respaldan la hipótesis de que el colapso de RoBERTa-BNE en la Fase 1 se debiera a la falta de datos para ajustar 125 millones de parámetros. Con apenas 300 noticias de entrenamiento —menos de la mitad de las 633 de la Fase 1—, el ajuste fino completo no colapsó en ninguna de las tres semillas y alcanzó un F1-macro de 0,930 ± 0,013 en prueba, por encima del cuerpo congelado (0,897 ± 0,011) y de TF-IDF + SVM (0,871 ± 0,006). La ventaja del ajuste completo sobre el congelado se mantuvo entre 3 y 4 puntos en los cuatro tamaños estudiados, sin cruce de curvas.

La evidencia apunta a la receta de entrenamiento. Con poco dato, el modelo pasa sus primeras épocas en una meseta con pérdida ≈ ln 2 = 0,693 (equivalente a responder al azar) y solo después empieza a aprender. En la Fase 1 la parada temprana detuvo el entrenamiento en la época 4, cuando el modelo todavía estaba en esa meseta. Con el corpus completo de 2.358 noticias, el ajuste completo obtuvo el mejor F1-macro en prueba (0,967 ± 0,007), aunque la regla preregistrada, aplicada sobre validación, eligió el descongelamiento parcial (0,979 frente a 0,971).

1. Pregunta y diseño experimental

En la retroalimentación de la Fase 1 el profesor planteó que «125 millones de parámetros ajustándose con 633 noticias de entrenamiento» no tienen señal suficiente, y pidió comparar regímenes para «decir si el colapso fue por tamaño del corpus o por régimen de ajuste». Para responderlo se compararon tres regímenes de transferencia de RoBERTa-BNE (`IsGarrido/roberta-base-bne` , commit `3d54a71`) bajo condiciones idénticas.

Régimen	Qué se entrena	Parámetros entrenables	Tasa elegida en validación
Congelado	Solo la cabeza de clasificación	592.130 (0,5 %)	3e-4
Parcial	2 últimas capas + cabeza	14.767.874 (11,8 %)	1,5e-4

Régimen	Qué se entrena	Parámetros entrenables	Tasa elegida en validación
Completo	Todo el modelo	124.644.866 (100 %)	2e-5

Quedaron fijos la partición de la Fase 2 (verificada fila por fila: 2.358 / 452 / 449, cero grupos con fuga), el protocolo ganador de la búsqueda bayesiana (lote 8, *dropout* 0,0726, *weight decay* 0,00855, reducción de tasa sobre meseta y parada temprana con paciencia 3 sobre el F1-macro de validación) y la regla de selección, preregistrada antes de entrenar. La tasa de aprendizaje de cada régimen se eligió en validación con la semilla 16, y la comparación se hizo con tres semillas independientes (42, 2026 y 7).

La curva de aprendizaje repitió los tres regímenes con 300, 633, 1.200 y 2.358 noticias de entrenamiento. Las submuestras son estratificadas y anidadas, distintas para cada semilla, y se evaluaron siempre sobre la misma validación y la misma prueba. Con 633 noticias se añadió un control con la tasa del artículo (1e-5). TF-IDF + SVM se reentrenó sobre las mismas submuestras como referencia.

2. Los tres regímenes con el corpus completo

Con 2.358 noticias, cuantos más parámetros se ajustaron, mejor fue el resultado en prueba. Los valores son media ± desviación de las semillas 42, 2026 y 7.

Modelo	Parámetros por noticia	F1-macro validación	F1-macro prueba	MCC prueba	Minutos por corrida
Congelado	251	0,948 ± 0,001	0,937 ± 0,008	0,876 ± 0,016	0,1
Parcial	6.263	**0,979 ± 0,005**	0,953 ± 0,005	0,905 ± 0,009	1,1
Completo	52.860	0,971 ± 0,004	**0,967 ± 0,007**	**0,935 ± 0,014**	3,3
TF-IDF + SVM	—	0,951	0,935	0,871	< 0,1 (CPU)

Tres observaciones sostienen la lectura:

- **El completo supera al congelado con significancia en las tres semillas** (McNemar exacto: p = 0,004, 0,001 y 0,003) y es el régimen que menos pierde de validación a prueba (−0,4 puntos, frente a −1,1 del congelado y −2,7 del parcial).

- **El cuerpo congelado iguala a TF-IDF** (0,937 frente a 0,935; p > 0,7 en las tres semillas). La representación preentrenada de RoBERTa-BNE, sin adaptar, contiene tanta información útil para la tarea como una bolsa de palabras.
- **La regla de selección y la prueba no coinciden.** La regla preregistrada eligió el parcial por validación, mientras que en prueba gana el completo. Entre ambos la evidencia está dividida (p = 0,057, 1,0 y 0,019), y la elección no se modificó después de ver la prueba.

El ajuste completo con la tasa ganadora de la búsqueda bayesiana en Keras (4,1e-5) fue inestable en PyTorch: con la semilla 16 colapsó en la época 2 (MCC 0) y terminó en 0,889 de F1 en validación. Con 2e-5, en cambio, las cuatro semillas probadas fueron estables.

3. Curva de aprendizaje: de 300 a 2.358 noticias

En ningún tamaño el cuerpo congelado superó al ajuste completo, y las curvas no se cruzan. La tabla muestra el F1-macro en prueba (media ± desviación, tres semillas); la Figura 1, al final de la sección, muestra las mismas cifras en prueba y en validación.

Noticias de entrenamiento	Congelado	Parcial	Completo	TF-IDF + SVM	Completo − congelado
300	0,897 ± 0,011	0,920 ± 0,019	**0,930 ± 0,013**	0,871 ± 0,006	+3,3 pts
633 (tamaño Fase 1)	0,904 ± 0,011	**0,943 ± 0,008**	0,938 ± 0,005	0,901 ± 0,005	+3,4 pts
1.200	0,921 ± 0,011	0,946 ± 0,007	**0,957 ± 0,006**	0,918 ± 0,005	+3,6 pts
2.358	0,937 ± 0,008	0,953 ± 0,005	**0,967 ± 0,007**	0,935 ± 0,000	+3,0 pts

Control con la tasa del artículo (ajuste completo, 1e-5, 633 noticias): 0,885 ± 0,044 en prueba, con una semilla en 0,835. Ninguna de las 39 corridas de la curva «no despegó» (MCC de validación por debajo de 0,2 en todas sus épocas), tampoco las del control.

De la tabla se desprenden cuatro patrones:

- **Adaptar el cuerpo ayuda incluso con muy poco dato.** Con 300 noticias, el ajuste completo mueve unos 415.000 parámetros por noticia y aun así supera al congelado por 3,3 puntos.

- **El valor de la transferencia crece cuando el corpus se achica.** La ventaja del completo sobre TF-IDF pasa de 3,2 puntos con 2.358 noticias a 5,9 con 300. Con 300 noticias, incluso el cuerpo congelado aventaja a TF-IDF por 2,6 puntos, mientras que con 633 o más ambos quedan prácticamente igualados.
- **Parcial y completo son indistinguibles hasta 1.200 noticias.** El parcial lidera con 633 y el completo con 300 y 1.200, siempre dentro de una desviación estándar.
- **El costo de tener poco dato es la variabilidad, no el colapso.** La desviación del completo en prueba baja de 0,013 con 300 noticias a 0,007 con 2.358, y la de validación de 0,017 a 0,004.

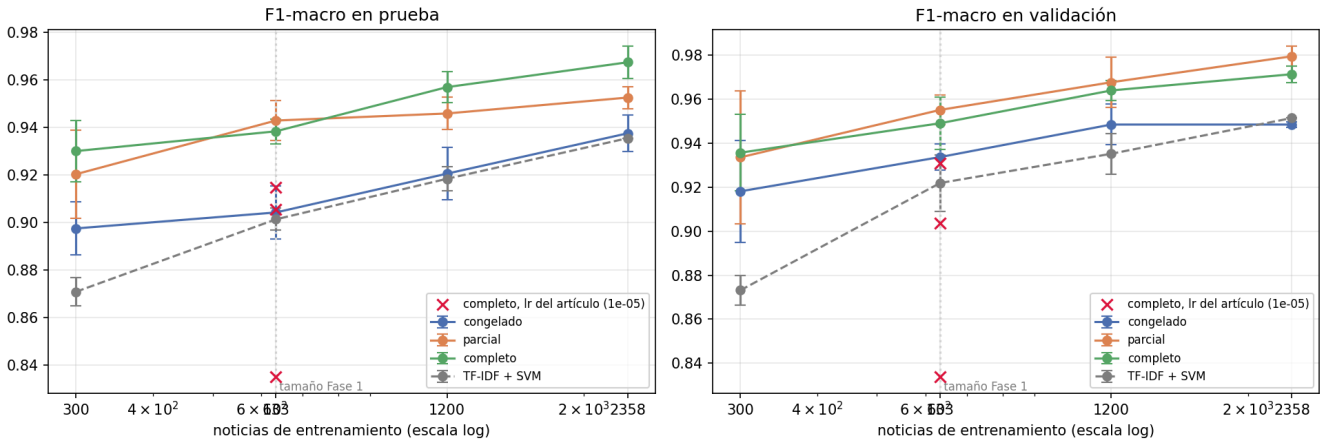


Figura 1. F1-macro en prueba (izquierda) y en validación (derecha) según el número de noticias de entrenamiento, en escala logarítmica. Cada punto es la media de tres semillas, con barras de ±1 desviación estándar; las cruces rojas son el control con la tasa del artículo (1e-5) en 633 noticias. Generada por `comparacion_regimenes_transferencia.ipynb`*, §24.*

4. Comparaciones por pares (McNemar exacto sobre las 449 noticias de prueba)

En todos los tamaños, el ajuste completo acertó más noticias que el congelado en las tres semillas. Entre el completo y el parcial, en cambio, casi nunca hubo diferencia significativa. Cada celda indica en cuántas de las tres semillas el primer régimen acertó más y en cuántas la diferencia fue significativa ($p < 0,05$), junto con la diferencia media de aciertos.

Noticias	Completo vs congelado	Completo vs parcial	Parcial vs congelado
300	3 de 3 · 2 sig. · +14,7	2 de 3 · 0 sig. · +4,3	3 de 3 · 1 sig. · +10,3

Noticias	Completo vs congelado	Completo vs parcial	Parcial vs congelado
633	3 de 3 · 2 sig. · +15,3	1 de 3 · 0 sig. · −2,0	3 de 3 · 2 sig. · +17,3
1.200	3 de 3 · 2 sig. · +16,3	2 de 3 · 0 sig. · +5,0	3 de 3 · 1 sig. · +11,3
2.358	3 de 3 · 3 sig. · +13,3	3 de 3 · 1 sig. · +6,7	3 de 3 · 1 sig. · +6,7

La comparación entre completo y congelado es la más sólida del estudio: la dirección se repite en las 12 parejas y es significativa en 9. Con 633 noticias, el mismo tamaño en el que colapsó la Fase 1, el completo acertó en promedio 15 noticias más que el congelado ($p = 0{,}0003$ con la semilla 7). Entre completo y parcial, solo 1 de 12 comparaciones fue significativa.

5. Por qué colapsó la Fase 1: una meseta inicial y una parada temprana impaciente

Con poco dato, el ajuste completo no arranca de inmediato: pasa una o dos épocas con pérdida de entrenamiento ≈ 0,693 ($\ln 2$, la de un clasificador que responde al azar) antes de empezar a aprender. Las seis corridas del completo con 300 y 633 noticias empezaron así, con una pérdida en la época 1 de entre 0,690 y 0,701. La Fase 1 se detuvo justamente dentro de esa meseta.

Época	Fase 1 · 633 noticias · receta del artículo	Fase 3 · 300 noticias · completo, semilla 2026	Fase 3 · 633 noticias · completo, semilla 7
1	pérdida 0,698 · F1 val 0,339	0,693 · 0,338	0,694 · 0,353
2	0,701 · 0,339	0,692 · 0,426	0,675 · 0,493
3	0,697 · 0,339	0,677 · 0,729	0,512 · 0,871
4	0,695 · 0,339 → **parada temprana**	0,632 · 0,382	0,325 · 0,895
6	—	0,364 · 0,781	0,110 · **0,958** (mejor)
12	—	0,143 · **0,924** (mejor)	—

En la Fase 1, el F1 de validación quedó idéntico (0,339, siempre la misma clase) durante tres épocas seguidas, y la parada temprana con paciencia 3 cortó el entrenamiento en la época 4. El modelo no «destruyó lo que sabía»: nunca llegó a empezar. Una pérdida de entrenamiento clavada en ln 2 indica que no se movió del punto de partida; un olvido catastrófico, en cambio, se vería como una pérdida de entrenamiento que baja mientras la validación empeora.

En la Fase 3, un pequeño avance del F1 de validación en la época 2 reinició la paciencia y le dio al modelo tiempo para salir de la meseta. Con 300 noticias, la mejor época llegó tarde (entre la 8 y la 15). El régimen parcial, por su parte, aprende desde la primera época (pérdida de 0,51 a 0,56 con 300 noticias): abrir solo las últimas capas con una tasa mayor acorta la meseta.

El control con la tasa del artículo (1e-5, lote 8, 633 noticias) sí salió de la meseta en las tres semillas, pero de forma más lenta e irregular, y la parada temprana lo cortó antes de converger en una de ellas (mejor época 2, F1 de prueba 0,835). Por eso, la tasa por sí sola no reproduce el colapso total. Lo que lo explica es la combinación de la receta de la Fase 1: tasa baja con calentamiento y decaimiento lineal, lote 16 (la mitad de pasos por época: 40 frente a 80) y una paciencia de 3 épocas medida sobre una métrica que no se mueve mientras el modelo está en la meseta. Esta lectura coincide con lo que describen Mosbach et al. (2021): la inestabilidad del ajuste fino en conjuntos pequeños se debe a dificultades de optimización y a muy pocas iteraciones de entrenamiento, no al tamaño del conjunto en sí.

6. Discusión: ¿tamaño del corpus o régimen de ajuste?

La pregunta del profesor admite ahora una respuesta con evidencia: en este corpus, el colapso de la Fase 1 se explica por la receta de entrenamiento y no por el tamaño del corpus. Tres hechos lo sostienen:

1. **Con el mismo tamaño de la Fase 1, el ajuste completo funciona.** Con 633 noticias alcanzó 0,938 ± 0,005 en prueba sin colapsar ninguna semilla, y con 300 noticias, 0,930 ± 0,013.
2. **Con poco dato, congelar no ayuda.** Si la falta de señal para mover millones de pesos fuera el problema, el régimen congelado debería ganar con 300 o 633 noticias y la ventaja del ajuste completo debería aparecer solo al crecer el corpus. Ocurrió lo contrario: la ventaja del completo es estable (de 3,0 a 3,6 puntos) en todos los tamaños.

3. **La dinámica del colapso corresponde a un fallo de optimización.** La pérdida de entrenamiento de la Fase 1 no se movió de ln 2, y la de la Fase 3, con la misma cantidad de datos, salió de esa meseta en la época 2 o 3.

La intuición del profesor tiene, sin embargo, una parte de razón que conviene reconocer. Con poco dato, el ajuste completo es más lento al arrancar, más variable entre semillas y más sensible a la tasa de aprendizaje: con 4,1e-5 colapsó una semilla incluso con 2.358 noticias, y con 1e-5 el control perdió hasta 10 puntos en una semilla. La aritmética de «parámetros por ejemplo» no determina si el modelo aprende, pero sí estrecha el margen de hiperparámetros que funcionan. En ese sentido, el descongelamiento parcial resulta la opción más robusta: aprende desde la primera época, cuesta un tercio del tiempo del completo y es estadísticamente indistinguible de él hasta 1.200 noticias.

Tampoco el modelo preentrenado es el problema. Su representación congelada ya iguala a TF-IDF con 633 o más noticias y lo supera con 300, y la adaptación del cuerpo añade de forma consistente unos 3 puntos.

Queda una advertencia que ningún régimen resuelve. El 97,5 % de las noticias del corpus proviene de un sitio que publica una sola clase, y la auditoría de interpretabilidad mostró que el modelo marca como falsas el 29 % de las noticias reales de otros medios reputables, frente al 0 % de El Espectador. Un F1-macro de 0,967 mide qué tan bien el modelo separa estas fuentes, no necesariamente qué tan bien distingue la veracidad. Este estudio responde qué régimen de transferencia conviene; no demuestra qué aprende el modelo.

7. Limitaciones

- **No son los mismos datos de la Fase 1.** Las submuestras de 633 noticias salen del corpus ampliado de 3.259, que tiene otra mezcla de fuentes que el corpus original de 793. Se comparó el tamaño, no los mismos ejemplos.
- **El control de la receta del artículo es parcial.** Solo cambió la tasa (1e-5); el lote 16, el calentamiento, el decaimiento lineal y el *dropout* 0,15 de la Fase 1 no se reprodujeron. Atribuir el colapso a esa combinación es una inferencia, no una prueba directa.
- **Las tasas se eligieron con 2.358 noticias** y se mantuvieron en todos los tamaños. Con poco dato, la tasa óptima de cada régimen podría ser otra, lo que puede perjudicar sobre todo al congelado y al parcial.
- **Tres semillas por celda** dan una idea de la variabilidad, no intervalos precisos. Parte de las diferencias de 1 a 2 puntos están dentro del ruido.

- **El protocolo común proviene de una búsqueda hecha para el ajuste completo.** Elegir la tasa por régimen corrige la mayor parte de ese sesgo, pero no todo.
- **La validación (452) y la prueba (449) son pequeñas**: un punto de F1 equivale a unas 4 o 5 noticias.
- **La partición sigue siendo aleatoria por grupos**, no temporal ni por fuente, así que todos los regímenes pueden apoyarse en el estilo de cada medio.
- **La partición de la Fase 2 depende de la versión de scikit-learn.** Con la versión actual de Colab se obtiene otra; este estudio usó la original, incrustada y verificada fila por fila.

8. Próximos pasos

- [ ] **Cerrar la inferencia sobre la Fase 1 con una sola corrida.** Volver a ejecutar el cuaderno de la Fase 1 sobre el corpus original de 793 noticias con su misma receta, pero sin parada temprana (paciencia de 10 o desactivada). Si sale de la meseta, queda probado que el colapso fue la parada prematura.
- [ ] **Partición temporal**: entrenar con las noticias más antiguas y evaluar con las más recientes, como pidió el profesor.
- [ ] **Prueba dejando medios fuera del entrenamiento**: entrenar sin un medio y evaluar con él, para medir cuánto del F1 es reconocimiento de la fuente.
- [ ] **Subir al repositorio** `particion_fase2.csv`, el cuaderno ejecutado y los archivos de resultados.

Evidencias

Todas las cifras de este informe salen de archivos generados por `comparacion_regimenes_transferencia.ipynb`, en la carpeta de Drive `DL_fase3_regimenes/`:

Archivo	Contenido
`tabla_regimenes.csv`, `todas_las_corridas.csv`	Resultados de los tres regímenes (fases A y B)
`seleccion_regimen.json`	Decisión preregistrada, con su fecha (14/11/2026, 12:29 hora de Bogotá)

Archivo	Contenido
`mcnemar_prueba.csv`	Comparaciones por pares con el corpus completo
`curva_aprendizaje/resumen_curva.csv`, `corridas_curva.csv`	Curva de aprendizaje: 39 corridas
`curva_aprendizaje/mcnemar_curva.csv`	Comparaciones por pares en cada tamaño
`runs/*/historial.csv`, `curva_aprendizaje/runs/*/historial.csv`	Pérdida y métricas por época de cada corrida

Referencias

- Blanco-Fernández, Y., Otero-Vizoso, J., Gil-Solla, A. y García-Duque, J. (2024). Enhancing misinformation detection in Spanish language with deep learning: BERT and RoBERTa transformer models. *Applied Sciences, 14*(21), 9729. https://doi.org/10.3390/app14219729
- Mosbach, M., Andriushchenko, M. y Klakow, D. (2021). On the stability of fine-tuning BERT: Misconceptions, explanations, and strong baselines. *International Conference on Learning Representations (ICLR)*.